



# 《机器学习公式详解》 (南瓜书)

## 第3章 一元线性回归

本节主讲：谢文睿

西瓜书对应章节：3.1、3.2

1. 算法原理
2. 线性回归的最小二乘估计和极大似然估计
3. 求解 $w$ 和 $b$

举一个通过【发际线的高度】预测【计算机水平】的例子

仅通过【发际线高度】预测【计算机水平】：

$$f(x) = w_1 x_1 + b$$

+二值离散特征【颜值】（好看：1，不好看：0）

$$f(x) = w_1 x_1 + w_2 x_2 + b$$

+有序的多值离散特征【饭量】（小：1，中：2，大：3）

$$f(x) = w_1 x_1 + w_2 x_2 + w_3 x_3 + b$$

+无序的多值离散特征【肤色】（黄：[1,0,0]，黑：[0,1,0]，白：[0,0,1]）

$$f(x) = w_1 x_1 + w_2 x_2 + w_3 x_3 + w_4 x_4 + w_5 x_5 + w_6 x_6 + b$$

基于均方误差最小化来进行模型求解的方法称为“最小二乘法”

$$\begin{aligned} E_{(w,b)} &= \sum_{i=1}^m (y_i - f(x_i))^2 \\ &= \sum_{i=1}^m (y_i - (wx_i + b))^2 \\ &= \sum_{i=1}^m (y_i - wx_i - b)^2 \end{aligned}$$

此即为公式3.4  $\arg \min_{(w,b)}$ （解释一下）后面的部分

用途：估计概率分布的参数值

方法：对于离散型（连续型）随机变量 $X$ ，假设其概率质量函数为 $P(x; \theta)$ （概率密度函数为 $p(x; \theta)$ ），其中 $\theta$ 为待估计的参数值（可以有多个）。现有 $x_1, x_2, x_3, \dots, x_n$ 是来自 $X$ 的 $n$ 个独立同分布的样本，它们的联合概率为

$$L(\theta) = \prod_{i=1}^n P(x_i; \theta)$$

其中 $x_1, x_2, x_3, \dots, x_n$ 是已知量， $\theta$ 是未知量，因此以上概率是一个关于 $\theta$ 的函数，称 $L(\theta)$ 为样本的似然函数。极大似然估计的直观想法：使得观测样本出现概率最大的分布就是待求分布，也即使得联合概率（似然函数） $L(\theta)$ 取到最大值的 $\theta^*$ 即为 $\theta$ 的估计值。

例题：现有一批观测样本 $x_1, x_2, x_3, \dots, x_n$ ，假设其服从某个正态分布 $X \sim N(\mu, \sigma^2)$ ，其中 $\mu, \sigma$ 为待估计的参数值，请用极大似然估计法估计 $\mu, \sigma$

【解】：第一步：写出随机变量 $X$ 的概率密度函数

$$p(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

第二步：写出似然函数

$$L(\mu, \sigma^2) = \prod_{i=1}^n p(x_i; \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

第三步：求出使得 $L(\mu, \sigma^2)$ 取到最大值的 $\mu, \sigma$

由于对数函数 $\ln$ 是单调递增函数，所以 $\ln L(\mu, \sigma^2)$ 和 $L(\mu, \sigma^2)$ 拥有相同的最大值点，而且利用对数函数的性质可以化简 $L(\mu, \sigma^2)$ 中的连乘项，因此通常会用 $\ln L(\mu, \sigma^2)$ 代替 $L(\mu, \sigma^2)$ 来求 $\mu, \sigma$ ，加了对数函数符号的似然函数 $\ln L(\mu, \sigma^2)$ 称为对数似然函数。

$$\begin{aligned}\ln L(\mu, \sigma^2) &= \ln \left[ \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp \left( -\frac{(x_i - \mu)^2}{2\sigma^2} \right) \right] \\ &= \sum_{i=1}^n \ln \frac{1}{\sqrt{2\pi}\sigma} \exp \left( -\frac{(x_i - \mu)^2}{2\sigma^2} \right)\end{aligned}$$

推荐视频：张宇考研数学——《概率论与数理统计》

推荐教材：陈希孺.《概率论与数理统计》、盛骤等.《概率论与数理统计》



对于线性回归来说，也可以假设其为以下模型

$$y = wx + b + \epsilon$$

其中 $\epsilon$ 为不受控制的随机误差，通常假设其服从均值为0的正态分布 $\epsilon \sim N(0, \sigma^2)$ （高斯提出的，也可以用中心极限定理解释），所以 $\epsilon$ 的概率密度函数为

$$p(\epsilon) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{\epsilon^2}{2\sigma^2}\right)$$

若将 $\epsilon$ 用 $y - (wx + b)$ 等价替换可得

$$p(y) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y - (wx + b))^2}{2\sigma^2}\right)$$

上式显然可以看作  $y \sim N(wx + b, \sigma^2)$ ，下面便可以用极大似然估计来估计  $w$  和  $b$  的值，似然函数为

$$\begin{aligned} L(w, b) &= \prod_{i=1}^m p(y_i) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} \exp \left( -\frac{(y_i - (wx_i + b))^2}{2\sigma^2} \right) \\ \ln L(w, b) &= \sum_{i=1}^m \ln \frac{1}{\sqrt{2\pi}\sigma} \exp \left( -\frac{(y_i - wx_i - b)^2}{2\sigma^2} \right) \\ &= \sum_{i=1}^m \ln \frac{1}{\sqrt{2\pi}\sigma} + \sum_{i=1}^m \ln \exp \left( -\frac{(y_i - wx_i - b)^2}{2\sigma^2} \right) \end{aligned}$$

$$\ln L(w, b) = m \ln \frac{1}{\sqrt{2\pi}\sigma} - \frac{1}{2\sigma^2} \sum_{i=1}^m (y_i - wx_i - b)^2$$

其中 $m, \sigma$ 均为常数，所以最大化 $\ln L(w, b)$ 等价于最小化 $\sum_{i=1}^m (y_i - wx_i - b)^2$ ，也即

$$(w^*, b^*) = \arg \max_{(w, b)} \ln L(w, b) = \arg \min_{(w, b)} \sum_{i=1}^m (y_i - wx_i - b)^2$$

此即为公式3.4，等价于最小二乘估计。

拓展阅读：靳志辉.《正态分布的前世今生》

$$(w^*, b^*) = \arg \min_{(w, b)} \sum_{i=1}^m (y_i - wx_i - b)^2$$

求解 $w$ 和 $b$ 其本质上是一个多元函数求最值（点）的问题，更具体点是凸函数求最值的问题。

推导思路：

1. 证明 $E_{(w, b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$ 是关于 $w$ 和 $b$ 的凸函数
2. 用凸函数求最值的思路求解出 $w$ 和 $b$

凸集：设集合 $D \subset \mathbb{R}^n$ ，如果对任意的 $\mathbf{x}, \mathbf{y} \in D$ 与任意的 $\alpha \in [0, 1]$ ，有

$$\alpha \mathbf{x} + (1 - \alpha) \mathbf{y} \in D$$

则称集合 $D$ 是凸集。凸集的几何意义是：若两个点属于此集合，则这两点连线上的任意一点均属于此集合（此处应该有图）。常见的凸集有空集 $\emptyset$ ， $n$ 维欧式空间 $\mathbb{R}^n$

凸函数：设 $D$ 是非空凸集， $f$ 是定义在 $D$ 上的函数，如果对任意的 $\mathbf{x}^1, \mathbf{x}^2 \in D, \alpha \in (0, 1)$ ，均有

$$f(\alpha \mathbf{x}^1 + (1 - \alpha) \mathbf{x}^2) \leq \alpha f(\mathbf{x}^1) + (1 - \alpha) f(\mathbf{x}^2)$$

则称 $f$ 为 $D$ 上的凸函数（此处也应该有图）。

推荐教材：王燕军.《最优化基础理论与方法》

梯度（多元函数的一阶导数）：设 $n$ 元函数 $f(\boldsymbol{x})$ 对自变量 $\boldsymbol{x} = (x_1, x_2, \dots, x_n)^T$ 的各分量 $x_i$ 的偏导数 $\frac{\partial f(\boldsymbol{x})}{\partial x_i}$  ( $i = 1, \dots, n$ )都存在，则称函数 $f(\boldsymbol{x})$ 在 $\boldsymbol{x}$ 处一阶可导，并称向量

$$\nabla f(\boldsymbol{x}) = \begin{bmatrix} \frac{\partial f(\boldsymbol{x})}{\partial x_1} \\ \frac{\partial f(\boldsymbol{x})}{\partial x_2} \\ \vdots \\ \frac{\partial f(\boldsymbol{x})}{\partial x_n} \end{bmatrix}$$

为函数 $f(\boldsymbol{x})$ 在 $\boldsymbol{x}$ 处的一阶导数或梯度（说一下为啥是列向量）。

Hessian（海塞）矩阵（多元函数的二阶导数）：设 $n$ 元函数 $f(\mathbf{x})$ 对自变量 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ 的各分量 $x_i$ 的二阶偏导数 $\frac{\partial^2 f(\mathbf{x})}{\partial x_i \partial x_j}$ （ $i = 1, 2, \dots, n; j = 1, 2, \dots, n$ ）都存在，则称函数 $f(\mathbf{x})$ 在 $\mathbf{x}$ 处二阶可导，并称矩阵

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f(\mathbf{x})}{\partial x_1^2} & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_2^2} & \cdots & \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f(\mathbf{x})}{\partial x_n^2} \end{bmatrix}$$

为函数 $f(\mathbf{x})$ 在 $\mathbf{x}$ 处的二阶导数或Hessian（海塞）矩阵。

定理：设 $D \subset \mathbb{R}^n$ 是非空开凸集， $f : D \subset \mathbb{R}^n \rightarrow \mathbb{R}$ ，且 $f(\mathbf{x})$ 在 $D$ 上二阶连续可微，如果 $f(\mathbf{x})$ 的Hessian（海塞）矩阵在 $D$ 上是半正定的，则 $f(\mathbf{x})$ 是 $D$ 上的凸函数。（类比一元函数判断凹凸性）

因此，只需证明 $E_{(w,b)} = \sum_{i=1}^m (y_i - wx_i - b)^2$ 的Hessian（海塞）矩阵

$$\nabla^2 E_{(w,b)} = \begin{bmatrix} \frac{\partial^2 E_{(w,b)}}{\partial w^2} & \frac{\partial^2 E_{(w,b)}}{\partial w \partial b} \\ \frac{\partial^2 E_{(w,b)}}{\partial b \partial w} & \frac{\partial^2 E_{(w,b)}}{\partial b^2} \end{bmatrix}$$

是半正定的，那么 $E_{(w,b)}$ 就是关于 $w$ 和 $b$ 的凸函数。



## 求解 $w$ 和 $b$

$$\begin{aligned}\frac{\partial E_{(w,b)}}{\partial w} &= \frac{\partial}{\partial w} \left[ \sum_{i=1}^m (y_i - wx_i - b)^2 \right] \\ &= \sum_{i=1}^m \frac{\partial}{\partial w} (y_i - wx_i - b)^2 \\ &= \sum_{i=1}^m 2 \cdot (y_i - wx_i - b) \cdot (-x_i) \\ &= 2 \left( w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) x_i \right) \text{ 此即为公式3.5}\end{aligned}$$

$$\begin{aligned}\frac{\partial E_{(w,b)}}{\partial w^2} &= \frac{\partial}{\partial w} \left( \frac{\partial E_{(w,b)}}{\partial w} \right) \\ &= \frac{\partial}{\partial w} \left[ 2 \left( w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) x_i \right) \right] \\ &= \frac{\partial}{\partial w} \left( 2w \sum_{i=1}^m x_i^2 \right) \\ &= 2 \sum_{i=1}^m x_i^2\end{aligned}$$

## 求解 $w$ 和 $b$

$$\begin{aligned}\frac{\partial E_{(w,b)}}{\partial w \partial b} &= \frac{\partial}{\partial b} \left( \frac{\partial E_{(w,b)}}{\partial w} \right) \\&= \frac{\partial}{\partial b} \left[ 2 \left( w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) x_i \right) \right] \\&= \frac{\partial}{\partial b} \left[ -2 \sum_{i=1}^m (y_i - b) x_i \right] \\&= \frac{\partial}{\partial b} \left( -2 \sum_{i=1}^m y_i x_i + 2 \sum_{i=1}^m b x_i \right) \\&= 2 \sum_{i=1}^m x_i\end{aligned}$$

$$\begin{aligned}\frac{\partial E_{(w,b)}}{\partial b} &= \frac{\partial}{\partial b} \left[ \sum_{i=1}^m (y_i - wx_i - b)^2 \right] \\ &= \sum_{i=1}^m \frac{\partial}{\partial b} (y_i - wx_i - b)^2 \\ &= \sum_{i=1}^m 2 \cdot (y_i - wx_i - b) \cdot (-1) \\ &= 2 \left( mb - \sum_{i=1}^m (y_i - wx_i) \right) \text{ 此即为公式3.6}\end{aligned}$$

## 求解 $w$ 和 $b$

$$\begin{aligned}\frac{\partial E_{(w,b)}}{\partial b \partial w} &= \frac{\partial}{\partial w} \left( \frac{\partial E_{(w,b)}}{\partial b} \right) \\ &= \frac{\partial}{\partial w} \left[ 2 \left( mb - \sum_{i=1}^m (y_i - wx_i) \right) \right] \\ &= \frac{\partial}{\partial w} \left( 2 \sum_{i=1}^m wx_i \right) \\ &= 2 \sum_{i=1}^m x_i\end{aligned}$$

$$\begin{aligned}\frac{\partial^2 E_{(w,b)}}{\partial b^2} &= \frac{\partial}{\partial b} \left( \frac{\partial E_{(w,b)}}{\partial b} \right) \\ &= \frac{\partial}{\partial b} \left[ 2 \left( mb - \sum_{i=1}^m (y_i - wx_i) \right) \right] \\ &= 2m\end{aligned}$$

$$\nabla^2 E_{(w,b)} = \begin{bmatrix} \frac{\partial^2 E_{(w,b)}}{\partial w^2} & \frac{\partial^2 E_{(w,b)}}{\partial w \partial b} \\ \frac{\partial^2 E_{(w,b)}}{\partial b \partial w} & \frac{\partial^2 E_{(w,b)}}{\partial b^2} \end{bmatrix} = \begin{bmatrix} 2 \sum_{i=1}^m x_i^2 & 2 \sum_{i=1}^m x_i \\ 2 \sum_{i=1}^m x_i & 2m \end{bmatrix}$$

半正定矩阵的判定定理之一：若实对称矩阵的所有顺序主子式均为非负，则该矩阵为半正定矩阵。

$$\begin{aligned} & \left| 2 \sum_{i=1}^m x_i^2 \right| > 0 \\ & \left| \begin{array}{cc} 2 \sum_{i=1}^m x_i^2 & 2 \sum_{i=1}^m x_i \\ 2 \sum_{i=1}^m x_i & 2m \end{array} \right| = 2 \sum_{i=1}^m x_i^2 \cdot 2m - 2 \sum_{i=1}^m x_i \cdot 2 \sum_{i=1}^m x_i \\ & = 4m \sum_{i=1}^m x_i^2 - 4 \left( \sum_{i=1}^m x_i \right)^2 \end{aligned}$$

$$\begin{aligned} 4m \sum_{i=1}^m x_i^2 - 4 \left( \sum_{i=1}^m x_i \right)^2 &= 4m \sum_{i=1}^m x_i^2 - 4 \cdot m \cdot \frac{1}{m} \cdot \left( \sum_{i=1}^m x_i \right)^2 \\ &= 4m \sum_{i=1}^m x_i^2 - 4m \cdot \bar{x} \cdot \sum_{i=1}^m x_i = 4m \left( \sum_{i=1}^m x_i^2 - \sum_{i=1}^m x_i \bar{x} \right) = 4m \sum_{i=1}^m (x_i^2 - x_i \bar{x}) \end{aligned}$$

$$\begin{aligned} \text{由于} \sum_{i=1}^m x_i \bar{x} &= \bar{x} \sum_{i=1}^m x_i = \bar{x} \cdot m \cdot \frac{1}{m} \cdot \sum_{i=1}^m x_i = m \bar{x}^2 = \sum_{i=1}^m \bar{x}^2 \\ &= 4m \sum_{i=1}^m (x_i^2 - x_i \bar{x} - x_i \bar{x} + x_i \bar{x}) = 4m \sum_{i=1}^m (x_i^2 - x_i \bar{x} - x_i \bar{x} + \bar{x}^2) = 4m \sum_{i=1}^m (x_i - \bar{x})^2 \end{aligned}$$

所以  $4m \sum_{i=1}^m (x_i - \bar{x})^2 \geq 0$ ，Hessian（海塞）矩阵  $\nabla^2 E_{(w,b)}$  的所有顺序主子式均非负，该矩阵为半正定矩阵，进而  $E_{(w,b)}$  是关于  $w$  和  $b$  的凸函数得证。



凸充分性定理：若  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  是凸函数，且  $f(\boldsymbol{x})$  一阶连续可微，则  $\boldsymbol{x}^*$  是全局解的充分必要条件是  $\nabla f(\boldsymbol{x}^*) = \mathbf{0}$

所以， $\nabla E_{(w,b)} = \mathbf{0}$  的点即为最小值点，也即

$$\nabla E_{(w,b)} = \begin{bmatrix} \frac{\partial E_{(w,b)}}{\partial w} \\ \frac{\partial E_{(w,b)}}{\partial b} \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\frac{\partial E_{(w,b)}}{\partial b} = 2 \left( mb - \sum_{i=1}^m (y_i - wx_i) \right) = 0$$

$$mb - \sum_{i=1}^m (y_i - wx_i) = 0$$

$$b = \frac{1}{m} \sum_{i=1}^m (y_i - wx_i) \text{ 公式3.8}$$

为了便于后续求解 $w$ ，在此对 $b$ 进行化简

$$b = \frac{1}{m} \sum_{i=1}^m y_i - w \cdot \frac{1}{m} \sum_{i=1}^m x_i = \bar{y} - w\bar{x}$$

$$\frac{\partial E_{(w,b)}}{\partial w} = 2 \left( w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) x_i \right) = 0$$

$$w \sum_{i=1}^m x_i^2 - \sum_{i=1}^m (y_i - b) x_i = 0$$

$$w \sum_{i=1}^m x_i^2 = \sum_{i=1}^m y_i x_i - \sum_{i=1}^m b x_i$$

把 $b = \bar{y} - w\bar{x}$ 代入上式可得

$$w \sum_{i=1}^m x_i^2 = \sum_{i=1}^m y_i x_i - \sum_{i=1}^m (\bar{y} - w\bar{x}) x_i$$

$$w \sum_{i=1}^m x_i^2 = \sum_{i=1}^m y_i x_i - \bar{y} \sum_{i=1}^m x_i + w \bar{x} \sum_{i=1}^m x_i$$

$$w \sum_{i=1}^m x_i^2 - w \bar{x} \sum_{i=1}^m x_i = \sum_{i=1}^m y_i x_i - \bar{y} \sum_{i=1}^m x_i$$

$$w \left( \sum_{i=1}^m x_i^2 - \bar{x} \sum_{i=1}^m x_i \right) = \sum_{i=1}^m y_i x_i - \bar{y} \sum_{i=1}^m x_i$$

## 求解 $w$ 和 $b$

$$w = \frac{\sum_{i=1}^m y_i x_i - \bar{y} \sum_{i=1}^m x_i}{\sum_{i=1}^m x_i^2 - \bar{x} \sum_{i=1}^m x_i}$$

其中

$$\bar{y} \sum_{i=1}^m x_i = \frac{1}{m} \sum_{i=1}^m y_i \sum_{i=1}^m x_i = \bar{x} \sum_{i=1}^m y_i$$

$$\bar{x} \sum_{i=1}^m x_i = \frac{1}{m} \sum_{i=1}^m x_i \sum_{i=1}^m x_i = \frac{1}{m} \left( \sum_{i=1}^m x_i \right)^2$$

所以

$$w = \frac{\sum_{i=1}^m y_i x_i - \bar{x} \sum_{i=1}^m y_i}{\sum_{i=1}^m x_i^2 - \frac{1}{m} \left( \sum_{i=1}^m x_i \right)^2} = \frac{\sum_{i=1}^m y_i (x_i - \bar{x})}{\sum_{i=1}^m x_i^2 - \frac{1}{m} \left( \sum_{i=1}^m x_i \right)^2} \quad \text{公式3.7}$$

## 求解 $w$ 和 $b$

$w$ 的向量化参见《机器学习公式详解》（南瓜书）式（3.7）的解析~

## 机器学习三要素：

1. 模型：根据具体问题，确定假设空间
2. 策略：根据评价标准，确定选取最优模型的策略（通常会产出一个“损失函数”）
3. 算法：求解损失函数，确定最优模型

下一节：多元线性回归  
西瓜书对应章节：3.2



欢迎加入【南瓜书读者交流群】，我们将在群里进行答疑、勘误、本次直播回放、本次直播PPT发放、下次直播通知等最新资源发放和活动通知。

加入步骤：

1. 关注公众号【Datawhale】，发送【南瓜书】三个字获取机器人“小豚”的微信二维码
2. 添加“小豚”为微信好友，然后对“小豚”发送【南瓜书】三个字即可自动邀请进群

