



# 《机器学习公式详解》 (南瓜书)

## 第3章 二分类线性判别分析

本节主讲：谢文睿

西瓜书对应章节：3.4

1. 算法原理（模型）
2. 损失函数推导（策略）
3. 拉格朗日乘子法
4. 求解 $w$ （算法）
5. 广义特征值和广义瑞利商

从几何的角度，让全体训练样本经过投影后：

- 异类样本的中心尽可能远
- 同类样本的方差尽可能小

## 损失函数推导

经过投影后，异类样本的中心尽可能远（并非严格投影）：

$$\max \| \boldsymbol{w}^T \boldsymbol{\mu}_0 - \boldsymbol{w}^T \boldsymbol{\mu}_1 \|_2^2$$

$$\max \| | \boldsymbol{w} | \cdot | \boldsymbol{\mu}_0 | \cdot \cos \theta_0 - | \boldsymbol{w} | \cdot | \boldsymbol{\mu}_1 | \cdot \cos \theta_1 \|_2^2$$

经过投影后，同类样本的方差尽可能小（并非严格方差）：

$$\min \boldsymbol{w}^T \boldsymbol{\Sigma}_0 \boldsymbol{w}$$

$$\begin{aligned} \boldsymbol{w}^T \boldsymbol{\Sigma}_0 \boldsymbol{w} &= \boldsymbol{w}^T \left( \sum_{\boldsymbol{x} \in X_0} (\boldsymbol{x} - \boldsymbol{\mu}_0)(\boldsymbol{x} - \boldsymbol{\mu}_0)^T \right) \boldsymbol{w} \\ &= \sum_{\boldsymbol{x} \in X_0} (\boldsymbol{w}^T \boldsymbol{x} - \boldsymbol{w}^T \boldsymbol{\mu}_0)(\boldsymbol{x}^T \boldsymbol{w} - \boldsymbol{\mu}_0^T \boldsymbol{w}) \end{aligned}$$

$$\begin{aligned}\max J &= \frac{\|\mathbf{w}^T \boldsymbol{\mu}_0 - \mathbf{w}^T \boldsymbol{\mu}_1\|_2^2}{\mathbf{w}^T \boldsymbol{\Sigma}_0 \mathbf{w} + \mathbf{w}^T \boldsymbol{\Sigma}_1 \mathbf{w}} \\&= \frac{\|(\mathbf{w}^T \boldsymbol{\mu}_0 - \mathbf{w}^T \boldsymbol{\mu}_1)^T\|_2^2}{\mathbf{w}^T (\boldsymbol{\Sigma}_0 + \boldsymbol{\Sigma}_1) \mathbf{w}} \\&= \frac{\|(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)^T \mathbf{w}\|_2^2}{\mathbf{w}^T (\boldsymbol{\Sigma}_0 + \boldsymbol{\Sigma}_1) \mathbf{w}} \\&= \frac{[(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)^T \mathbf{w}]^T (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)^T \mathbf{w}}{\mathbf{w}^T (\boldsymbol{\Sigma}_0 + \boldsymbol{\Sigma}_1) \mathbf{w}} \\&= \frac{\mathbf{w}^T (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1) (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)^T \mathbf{w}}{\mathbf{w}^T (\boldsymbol{\Sigma}_0 + \boldsymbol{\Sigma}_1) \mathbf{w}}\end{aligned}$$

$$\max J = \frac{\boldsymbol{w}^T (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1) (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)^T \boldsymbol{w}}{\boldsymbol{w}^T (\boldsymbol{\Sigma}_0 + \boldsymbol{\Sigma}_1) \boldsymbol{w}}$$

$\Downarrow$

$$\max J = \frac{\boldsymbol{w}^T \boldsymbol{S}_b \boldsymbol{w}}{\boldsymbol{w}^T \boldsymbol{S}_w \boldsymbol{w}}$$

$\Downarrow$

$$\begin{aligned} \min_{\boldsymbol{w}} \quad & -\boldsymbol{w}^T \boldsymbol{S}_b \boldsymbol{w} \\ \text{s.t.} \quad & \boldsymbol{w}^T \boldsymbol{S}_w \boldsymbol{w} = 1 \end{aligned}$$

## 拉格朗日乘子法

对于仅含等式约束的优化问题（解释下为啥是min）：

$$\begin{aligned} \min_{\boldsymbol{x}} \quad & f(\boldsymbol{x}) \\ \text{s.t.} \quad & h_i(\boldsymbol{x}) = 0 \quad i = 1, 2, \dots, n \end{aligned}$$

其中自变量 $\boldsymbol{x} \in \mathbb{R}^n$ ， $f(\boldsymbol{x})$ 和 $h_i(\boldsymbol{x})$ 均有连续的一阶偏导数。首先列出其拉格朗日函数：

$$L(\boldsymbol{x}, \boldsymbol{\lambda}) = f(\boldsymbol{x}) + \sum_{i=1}^n \lambda_i h_i(\boldsymbol{x})$$

其中 $\boldsymbol{\lambda} = (\lambda_1, \lambda_2, \dots, \lambda_n)^T$ 为拉格朗日乘子。然后对拉格朗日函数关于 $\boldsymbol{x}$ 求偏导，并令导数等于0再搭配约束条件 $h_i(\boldsymbol{x}) = 0$ 解出 $\boldsymbol{x}$ ，求解出的所有 $\boldsymbol{x}$ 即为上述优化问题的所有可能【极值点】

$$\begin{aligned} \min_{\boldsymbol{w}} \quad & -\boldsymbol{w}^T \mathbf{S}_b \boldsymbol{w} \\ \text{s.t.} \quad & \boldsymbol{w}^T \mathbf{S}_w \boldsymbol{w} = 1 \Leftrightarrow \boldsymbol{w}^T \mathbf{S}_w \boldsymbol{w} - 1 = 0 \end{aligned}$$

由拉格朗日乘子法可得拉格朗日函数为

$$L(\boldsymbol{w}, \lambda) = -\boldsymbol{w}^T \mathbf{S}_b \boldsymbol{w} + \lambda(\boldsymbol{w}^T \mathbf{S}_w \boldsymbol{w} - 1)$$

对 $\boldsymbol{w}$ 求偏导可得

$$\begin{aligned} \frac{\partial L(\boldsymbol{w}, \lambda)}{\partial \boldsymbol{w}} &= -\frac{\partial(\boldsymbol{w}^T \mathbf{S}_b \boldsymbol{w})}{\partial \boldsymbol{w}} + \lambda \frac{\partial(\boldsymbol{w}^T \mathbf{S}_w \boldsymbol{w} - 1)}{\partial \boldsymbol{w}} \\ &= -(\mathbf{S}_b + \mathbf{S}_b^T) \boldsymbol{w} + \lambda(\mathbf{S}_w + \mathbf{S}_w^T) \boldsymbol{w} \end{aligned}$$

由于 $\mathbf{S}_b = \mathbf{S}_b^T$ ,  $\mathbf{S}_w = \mathbf{S}_w^T$ , 所以



$$\frac{\partial L(w, \lambda)}{\partial w} = -2S_b w + 2\lambda S_w w$$

令上式等于0即可得

$$-2S_b w + 2\lambda S_w w = 0$$

$$S_b w = \lambda S_w w$$

$$(\mu_0 - \mu_1)(\mu_0 - \mu_1)^T w = \lambda S_w w$$

若令 $(\mu_0 - \mu_1)^T w = \gamma$ , 则

$$\gamma(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1) = \lambda \mathbf{S}_w \mathbf{w}$$

$$\mathbf{w} = \frac{\gamma}{\lambda} \mathbf{S}_w^{-1} (\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)$$

由于最终要求解的 $\mathbf{w}$ 不关心其大小，只关心其方向，所以 $\frac{\gamma}{\lambda}$ 这个常数项可以任意取值，西瓜书中所说的“不妨令 $\mathbf{S}_b \mathbf{w} = \lambda(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)$ ”就等价于令 $\gamma = \lambda$ ，进而使得 $\frac{\gamma}{\lambda} = 1$ ，此时求解出的 $\mathbf{w}$ 即为公式(3.39)，另外，此处并未严格按照上述拉格朗日乘子法再刻意考虑等式约束条件 $\mathbf{w}^T \mathbf{S}_w \mathbf{w} - 1 = 0$ 也是因为不在乎 $\mathbf{w}$ 的大小。

此时用拉格朗日乘子法求出来的极值点 $w$ 一定是最小值点吗？

答：是的，因为 $-w^T S_b w = -\|w^T \mu_0 - w^T \mu_1\|_2^2 \leq 0$ ，所以目标函数最大值为0，且一定存在最小值，所以求出来的极值点只要代入目标函数不为0则一定是最小值点。

设 $\mathbf{A}, \mathbf{B}$ 为 $n$ 阶方阵，若存在数 $\lambda$ ，使得方程 $\mathbf{A}\mathbf{x} = \lambda\mathbf{B}\mathbf{x}$ 存在非零解，则称 $\lambda$ 为 $\mathbf{A}$ 相对于 $\mathbf{B}$ 的广义特征值， $\mathbf{x}$ 为 $\mathbf{A}$ 相对于 $\mathbf{B}$ 的属于广义特征值 $\lambda$ 的特征向量。特别地，当 $\mathbf{B} = \mathbf{I}$ （单位矩阵）时，广义特征值问题退化为标准特征值问题。

设 $\mathbf{A}, \mathbf{B}$ 为 $n$ 阶厄米 (Hermitian) 矩阵, 且 $\mathbf{B}$ 正定, 称 $R(\mathbf{x}) = \frac{\mathbf{x}^H \mathbf{A} \mathbf{x}}{\mathbf{x}^H \mathbf{B} \mathbf{x}} (\mathbf{x} \neq \mathbf{0})$ 为 $\mathbf{A}$ 相对于 $\mathbf{B}$ 的广义瑞利商。特别地, 当 $\mathbf{B} = \mathbf{I}$  (单位矩阵) 时, 广义瑞利商退化为瑞利商。

广义瑞利商的性质：设 $\lambda_i, \mathbf{x}_i (i = 1, 2, \dots, n)$ 为 $\mathbf{A}$ 相对于 $\mathbf{B}$ 的广义特征值和特征向量，且 $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ 。

$$\min_{\mathbf{x} \neq \mathbf{0}} R(\mathbf{x}) = \frac{\mathbf{x}^H \mathbf{A} \mathbf{x}}{\mathbf{x}^H \mathbf{B} \mathbf{x}} = \lambda_1, \mathbf{x}^* = \mathbf{x}_1$$

$$\max_{\mathbf{x} \neq \mathbf{0}} R(\mathbf{x}) = \frac{\mathbf{x}^H \mathbf{A} \mathbf{x}}{\mathbf{x}^H \mathbf{B} \mathbf{x}} = \lambda_n, \mathbf{x}^* = \mathbf{x}_n$$

【证明】：当固定 $\mathbf{x}^H \mathbf{B} \mathbf{x} = 1$ 时，使用拉格朗日乘子法可推得 $\mathbf{A} \mathbf{x} = \lambda \mathbf{B} \mathbf{x}$ 这样一个广义特征值问题，因此 $\mathbf{x}$ 所有可能的解即为 $\mathbf{x}_i (i = 1, 2, \dots, n)$ 这 $n$ 个广义特征向量，将其分别代入 $R(\mathbf{x})$ 即可推得上述结论。

下一节：决策树

西瓜书对应章节：4.1、4.2

欢迎加入【南瓜书读者交流群】，我们将在群里进行答疑、勘误、本次直播回放、本次直播PPT发放、下次直播通知等最新资源发放和活动通知。

加入步骤：

1. 关注公众号【Datawhale】，发送【南瓜书】三个字获取机器人“小豚”的微信二维码
2. 添加“小豚”为微信好友，然后对“小豚”发送【南瓜书】三个字即可自动邀请进群、

