



《机器学习公式详解》 (南瓜书)

第3章 对数几率回归

本节主讲：谢文睿

西瓜书对应章节：3.3

1. 算法原理
2. 损失函数的极大似然估计推导
3. 损失函数的信息论推导

在线性模型的基础上套一个映射函数来实现分类功能

拓展阅读: <https://sm1les.com/2019/01/17/logistic-regression-and-maximum-entropy/>

极大似然估计

第一步：确定概率质量函数（概率密度函数）

已知离散型随机变量 $y \in \{0, 1\}$ 取值为1和0的概率分别建模为

$$p(y = 1|\mathbf{x}) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}} = \frac{e^{\mathbf{w}^T \mathbf{x} + b}}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$$

$$p(y = 0|\mathbf{x}) = 1 - p(y = 1|\mathbf{x}) = \frac{1}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$$

为了便于讨论，令 $\boldsymbol{\beta} = (\mathbf{w}; b)$, $\hat{\mathbf{x}} = (\mathbf{x}; 1)$ ，则上式可简写为

$$p(y = 1|\hat{\mathbf{x}}; \boldsymbol{\beta}) = \frac{e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}} = p_1(\hat{\mathbf{x}}; \boldsymbol{\beta})$$

$$p(y = 0|\hat{\mathbf{x}}; \boldsymbol{\beta}) = \frac{1}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}} = p_0(\hat{\mathbf{x}}; \boldsymbol{\beta})$$

由以上概率取值可推得随机变量 $y \in \{0, 1\}$ 的概率质量函数为

$$p(y|\hat{\mathbf{x}}; \boldsymbol{\beta}) = y \cdot p_1(\hat{\mathbf{x}}; \boldsymbol{\beta}) + (1 - y) \cdot p_0(\hat{\mathbf{x}}; \boldsymbol{\beta}) \quad \text{此即为公式3.26}$$

或者为

$$p(y|\hat{\mathbf{x}}; \boldsymbol{\beta}) = [p_1(\hat{\mathbf{x}}; \boldsymbol{\beta})]^y [p_0(\hat{\mathbf{x}}; \boldsymbol{\beta})]^{1-y}$$

接下来的讲解采用第一种形式（西瓜书中所采用的），采用第二种形式来进行接下来的推导其实更简单，具体参见南瓜书式（3.27）的解析~

第二步：写出似然函数

$$L(\boldsymbol{\beta}) = \prod_{i=1}^m p(y_i | \hat{\mathbf{x}}_i; \boldsymbol{\beta})$$

对数似然函数为

$$\ell(\boldsymbol{\beta}) = \ln L(\boldsymbol{\beta}) = \sum_{i=1}^m \ln p(y_i | \hat{\mathbf{x}}_i; \boldsymbol{\beta})$$

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^m \ln (y_i p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta}) + (1 - y_i) p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta}))$$

将 $p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta}) = \frac{e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}}$, $p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta}) = \frac{1}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}}$ 代入上式可得

$$\begin{aligned}\ell(\boldsymbol{\beta}) &= \sum_{i=1}^m \ln \left(\frac{y_i e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}} + \frac{1 - y_i}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}} \right) \\ &= \sum_{i=1}^m \ln \left(\frac{y_i e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i} + 1 - y_i}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}} \right) \\ &= \sum_{i=1}^m \left(\ln(y_i e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i} + 1 - y_i) - \ln(1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}) \right)\end{aligned}$$

由于 $y_i \in \{0, 1\}$, 则

$$\ell(\boldsymbol{\beta}) = \begin{cases} \sum_{i=1}^m (-\ln(1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i})), & y_i = 0 \\ \sum_{i=1}^m (\boldsymbol{\beta}^T \hat{\mathbf{x}}_i - \ln(1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i})), & y_i = 1 \end{cases}$$

两式综合可得

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^m \left(y_i \boldsymbol{\beta}^T \hat{\mathbf{x}}_i - \ln(1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}) \right)$$

由于损失函数通常是以最小化为优化目标, 因此可以将最大化 $\ell(\boldsymbol{\beta})$ 等价转化为最小化 $\ell(\boldsymbol{\beta})$ 的相反数 $-\ell(\boldsymbol{\beta})$, 此即为公式(3.27)

信息论：以概率论、随机过程为基本研究工具，研究广义通信系统的整个过程。常见的应用有无损数据压缩（如ZIP文件）、有损数据压缩（如MP3和JPEG）等，本节仅引用部分精华内容。

自信息：

$$I(X) = -\log_b p(x)$$

当 $b = 2$ 时单位为bit，当 $b = e$ 时单位为nat

信息熵（自信息的期望）：度量随机变量 X 的不确定性，信息熵越大越不确定

$$H(X) = E[I(X)] = -\sum_x p(x) \log_b p(x) \quad (\text{此处以离散型为例})$$

计算信息熵时约定：若 $p(x) = 0$ ，则 $p(x) \log_b p(x) = 0$ （最大值和最小值的严格数学分析留到决策树讲解）

相对熵（KL散度）：度量两个分布的差异，其典型使用场景是用来度量理想分布 $p(x)$ 和模拟分布 $q(x)$ 之间的差异。

$$\begin{aligned} D_{KL}(p||q) &= \sum_x p(x) \log_b \left(\frac{p(x)}{q(x)} \right) \\ &= \sum_x p(x) (\log_b p(x) - \log_b q(x)) \\ &= \sum_x p(x) \log_b p(x) - \sum_x p(x) \log_b q(x) \end{aligned}$$

其中 $-\sum_x p(x) \log_b q(x)$ 称为交叉熵。

从机器学习三要素中“策略”的角度来说，与理想分布最接近的模拟分布即为最优分布，因此可以通过最小化相对熵这个策略来求出最优分布。由于理想分布 $p(x)$ 是未知但固定的分布（频率学派的角度），所以 $\sum_x p(x) \log_b p(x)$ 为常量，那么最小化相对熵就等价于最小化交叉熵 $-\sum_x p(x) \log_b q(x)$

以对数几率回归为例，对单个样本 y_i 来说，它的理想分布是

$$p(y_i) = \begin{cases} p(1) = 1, p(0) = 0, & y_i = 1 \\ p(1) = 0, p(0) = 1, & y_i = 0 \end{cases}$$

它现在的模拟分布是

$$q(y_i) = \begin{cases} \frac{e^{\beta^T \hat{x}}}{1 + e^{\beta^T \hat{x}}} = p_1(\hat{x}; \beta), & y_i = 1 \\ \frac{1}{1 + e^{\beta^T \hat{x}}} = p_0(\hat{x}; \beta), & y_i = 0 \end{cases}$$

那么单个样本 y_i 的交叉熵为

$$-\sum_{y_i} p(y_i) \log_b q(y_i)$$

$$-p(1) \cdot \log_b p_1(\hat{\mathbf{x}}; \boldsymbol{\beta}) - p(0) \cdot \log_b p_0(\hat{\mathbf{x}}; \boldsymbol{\beta})$$

$$-y_i \cdot \log_b p_1(\hat{\mathbf{x}}; \boldsymbol{\beta}) - (1 - y_i) \cdot \log_b p_0(\hat{\mathbf{x}}; \boldsymbol{\beta})$$

令 $b = e$

$$-y_i \ln p_1(\hat{\mathbf{x}}; \boldsymbol{\beta}) - (1 - y_i) \ln p_0(\hat{\mathbf{x}}; \boldsymbol{\beta})$$

全体训练样本的交叉熵为

$$\sum_{i=1}^m [-y_i \ln p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta}) - (1 - y_i) \ln p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta})]$$

$$\sum_{i=1}^m \{-y_i [\ln p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta}) - \ln p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta})] - \ln(p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta}))\}$$

$$\sum_{i=1}^m \left[-y_i \ln \left(\frac{p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta})}{p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta})} \right) - \ln(p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta})) \right]$$

$$\sum_{i=1}^m \left[-y_i \ln \left(\frac{\frac{e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}}}{\frac{1}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}}} \right) - \ln \left(\frac{1}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}} \right) \right]$$

$$\sum_{i=1}^m \left[-y_i \ln \left(e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i} \right) - \ln \left(\frac{1}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}} \right) \right]$$
$$\sum_{i=1}^m \left(-y_i \boldsymbol{\beta}^T \hat{\mathbf{x}}_i + \ln(1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}) \right)$$

此即为公式3.27

对数几率回归算法的机器学习三要素：

1. 模型：线性模型，输出值的范围为 $[0, 1]$ ，近似阶跃的单调可微函数
2. 策略：极大似然估计，信息论
3. 算法：梯度下降，牛顿法

下一节：二分类线性判别分析
西瓜书对应章节：3.4

欢迎加入【南瓜书读者交流群】，我们将在群里进行答疑、勘误、本次直播回放、本次直播PPT发放、下次直播通知等最新资源发放和活动通知。

加入步骤：

1. 关注公众号【Datawhale】，发送【南瓜书】三个字获取机器人“小豚”的微信二维码
2. 添加“小豚”为微信好友，然后对“小豚”发送【南瓜书】三个字即可自动邀请进群、

