



《机器学习公式详解》 (南瓜书)

第6章 软间隔与支持向量回归

本节主讲：谢文睿

西瓜书对应章节：6.4、6.5

1. 算法原理
2. 软间隔
3. 支持向量回归

在现实任务中，线性不可分的情形才是最常见的，因此需要允许支持向量机犯错

从数学角度来说，软间隔就是允许部分样本（但要尽可能少）不满足下式中的约束条件

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{aligned}$$

因此，可以将必须严格执行的约束条件转化为具有一定灵活性的“损失”，合格的损失函数要求如下：

- 当满足约束条件时，损失为0
- 当不满足约束条件时，损失不为0，
- （可选）当不满足约束条件时，损失与其违反约束条件的程度成正比

只有满足以上要求，才能保证在最小化（min）损失的过程中，保证不满足约束条件的样本尽可能的少。

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \ell_{0/1} (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1)$$

其中， $\ell_{0/1}$ 是“0/1损失函数”

$$\ell_{0/1}(z) = \begin{cases} 1, & \text{if } z < 0 \\ 0, & \text{if } z \geq 0 \end{cases}$$

$C > 0$ 是一个常数，用来调节损失的权重，显然当 $C \rightarrow +\infty$ 时，会迫使所有样本的损失为0，进而退化为严格执行的约束条件，退化为硬间隔，因此，本式子可以看作支持向量机的一般化形式。

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \ell_{0/1} (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1)$$

由于 $\ell_{0/1}$ 非凸、非连续，数学性质不好，使得上式不易求解，因此常用一些数学性质较好的“替代损失函数”来代替 $\ell_{0/1}$ ，软间隔支持向量机通常采用的是hinge（合页）损失来代替 $\ell_{0/1}$

$$\text{hinge损失: } \ell_{\text{hinge}}(z) = \max(0, 1 - z)$$

替换进上式可得

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i (\mathbf{w}^T \mathbf{x}_i + b))$$

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i (\mathbf{w}^T \mathbf{x}_i + b))$$

引入松弛变量 ξ_i ，上述优化问题便和下述优化问题等价

$$\begin{aligned} \min_{\mathbf{w}, b, \xi_i} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i \\ \text{s.t.} \quad & y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0, i = 1, 2, \dots, m \end{aligned}$$

【证明】：令

$$\max(0, 1 - y_i (\mathbf{w}^T \mathbf{x}_i + b)) = \xi_i$$

显然 $\xi_i \geq 0$ ，当 $1 - y_i (\mathbf{w}^T \mathbf{x}_i + b) > 0 \Rightarrow \xi_i = 1 - y_i (\mathbf{w}^T \mathbf{x}_i + b)$ ，当 $1 - y_i (\mathbf{w}^T \mathbf{x}_i + b) \leq 0 \Rightarrow \xi_i = 0$ ，所以

$$1 - y_i (\mathbf{w}^T \mathbf{x}_i + b) \leq \xi_i \Rightarrow y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$

相比于线性回归用**一条线**来拟合训练样本，支持向量回归（SVR）而是采用一个以 $f(\boldsymbol{x}) = \boldsymbol{w}^T \boldsymbol{x} + b$ 为中心，宽度为 2ϵ 的**间隔带**，来拟合训练样本。

落在带子上的样本不计算损失（类比线性回归在线上的点预测误差为0），不在带子上的则以偏离带子的距离作为损失（类比线性回归的均方误差），然后以最小化损失的方式迫使间隔带从样本最密集的地方（中心地带）穿过，进而达到拟合训练样本的目的。

因此SVR的优化问题可以写为

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \ell_{\epsilon}(f(\mathbf{x}_i) - y_i)$$

其中 $\ell_{\epsilon}(z)$ 为“ ϵ 不敏感损失函数”（类比均方误差损失）

$$\ell_{\epsilon}(z) = \begin{cases} 0, & \text{if } |z| \leq \epsilon \\ |z| - \epsilon, & \text{if } |z| > \epsilon \end{cases}$$

$\frac{1}{2} \|\mathbf{w}\|^2$ 为L2正则项，此处引入正则项除了起正则化本身的作用外，也是为了和（软间隔）支持向量机的优化目标保持形式上的一致（在这里不用均方误差也是此目的），这样就可以导出对偶问题引入核函数， C 为调节损失权重的常数。

$$\ell_{\epsilon}(z) = \begin{cases} 0, & \text{if } |z| \leq \epsilon \\ |z| - \epsilon, & \text{if } |z| > \epsilon \end{cases}$$

同软间隔支持向量机，引入松弛变量 ξ_i ，令

$$\ell_{\epsilon}(f(\mathbf{x}_i) - y_i) = \xi_i$$

显然 $\xi_i \geq 0$ ，并且

$$\text{当 } |f(\mathbf{x}_i) - y_i| \leq \epsilon \Rightarrow \xi_i = 0$$

$$\text{当 } |f(\mathbf{x}_i) - y_i| > \epsilon \Rightarrow \xi_i = |f(\mathbf{x}_i) - y_i| - \epsilon$$

所以

$$|f(\mathbf{x}_i) - y_i| - \epsilon \leq \xi_i \Rightarrow |f(\mathbf{x}_i) - y_i| \leq \epsilon + \xi_i$$

$$-\epsilon - \xi_i \leq f(\mathbf{x}_i) - y_i \leq \epsilon + \xi_i$$

那么SVR的优化问题可以改写为

$$\min_{\mathbf{w}, b, \xi_i} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i$$

$$\text{s.t.} \quad -\epsilon - \xi_i \leq f(\mathbf{x}_i) - y_i \leq \epsilon + \xi_i \\ \xi_i \geq 0, i = 1, 2, \dots, m$$

如果考虑两边采用不同的松弛程度

$$\min_{\mathbf{w}, b, \xi_i, \hat{\xi}_i} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m (\xi_i + \hat{\xi}_i)$$

$$\text{s.t.} \quad -\epsilon - \hat{\xi}_i \leq f(\mathbf{x}_i) - y_i \leq \epsilon + \xi_i \\ \xi_i \geq 0, \hat{\xi}_i \geq 0, i = 1, 2, \dots, m$$

下一节：贝叶斯分类

西瓜书对应章节：7.1、7.2、7.3

欢迎加入【南瓜书读者交流群】，我们将在群里进行答疑、勘误、本次直播回放、本次直播PPT发放、下次直播通知等最新资源发放和活动通知。

加入步骤：

1. 关注公众号【Datawhale】，发送【南瓜书】三个字获取机器人“小豚”的微信二维码
2. 添加“小豚”为微信好友，然后对“小豚”发送【南瓜书】三个字即可自动邀请进群

