



# 《机器学习公式详解》 (南瓜书)

## 第8章 集成学习

本节主讲：秦州

西瓜书对应章节：8.1、8.2

1. 个体与集成
2. Adaboost算法

“三个臭皮匠，顶个诸葛亮”，集成学习通过集合 **多个个体学习器** 的结果来提升预测结果的准确性和泛化能力。

“君子和而不同”个体学习器需要比随机猜想要强一些，个体学习器的预测结果也要具有一定的多样性。

	样本a	样本b	样本c		样本a	样本b	样本c		样本a	样本b	样本c
学习器1	1	1	0		1	0	0		1	1	0
学习器2	1	0	1		0	1	0		1	1	0
学习器3	0	1	1		0	0	1		1	1	0
集成结果	1	1	1		0	0	0		1	1	0

集成个体学习器的收敛性保证：

$$\begin{aligned} P(H(\mathbf{x}) \neq f(\mathbf{x})) &= \sum_{k=0}^{\lfloor T/2 \rfloor} \binom{T}{k} (1 - \epsilon)^k \epsilon^{T-k} \\ &\leq \exp \left( -\frac{1}{2} T (1 - 2\epsilon)^2 \right) \end{aligned}$$

两个基本结论：

- 收敛速率随着个体学习器数量 $T$ 呈指数下降
- $\epsilon = 0.5$ 的个体集成器对收敛没有作用

学习 $T$ 个个体学习器 $h_t$ 和相应的权重 $\alpha_t$ , 使得他们的加权和

$$H(\boldsymbol{x}) = \sum_{t=1}^T \alpha_t h_t(\boldsymbol{x})$$

能够最小化损失函数

$$\ell_{\text{exp}}(H \mid \mathcal{D}) = \mathbb{E}_{\boldsymbol{x} \sim \mathcal{D}} \left[ e^{-f(\boldsymbol{x})H(\boldsymbol{x})} \right]$$

**前向分布求解算法：** 每一轮只学习一个学习器 $h_t$ 和相应的权重 $\alpha_t$ ，第 $t$ 轮的优化目标

$$(\alpha_t, h_t) = \arg \min_{\alpha, h} \ell_{\text{exp}} (H_{t-1} + \alpha h \mid \mathcal{D})$$

根据指数损失函数的定义式(8.5)，有

$$\begin{aligned} \ell_{\text{exp}} (H_{t-1} + \alpha h \mid \mathcal{D}) &= \mathbb{E}_{\mathbf{x} \sim \mathcal{D}} \left[ e^{-f(\mathbf{x})(H_{t-1}(\mathbf{x}) + \alpha h(\mathbf{x}))} \right] \\ &= \sum_{i=1}^{|D|} \mathcal{D}(\mathbf{x}_i) e^{-f(\mathbf{x}_i)(H_{t-1}(\mathbf{x}_i) + \alpha h(\mathbf{x}_i))} \\ &= \sum_{i=1}^{|D|} \mathcal{D}(\mathbf{x}_i) e^{-f(\mathbf{x}_i)H_{t-1}(\mathbf{x}_i)} e^{-f(\mathbf{x}_i)\alpha h(\mathbf{x}_i)} \end{aligned}$$

因为 $f(x_i)$ 和 $h(x_i)$ 仅可取值 $\{-1, 1\}$ ，可以推得

$$\begin{aligned}\ell_{\text{exp}}(H_{t-1} + \alpha h \mid \mathcal{D}) &= \sum_{i=1}^{|D|} \mathcal{D}(\mathbf{x}_i) e^{-f(\mathbf{x}_i)H_{t-1}(\mathbf{x}_i)} (e^{-\alpha} + (e^{\alpha} - e^{-\alpha}) \mathbb{I}(f(\mathbf{x}_i) \neq h(\mathbf{x}_i))) \\ &= \sum_{i=1}^{|D|} \mathcal{D}(\mathbf{x}_i) e^{-f(\mathbf{x}_i)H_{t-1}(\mathbf{x}_i)} e^{-\alpha} + \sum_{i=1}^{|D|} \mathcal{D}(\mathbf{x}_i) e^{-f(\mathbf{x}_i)H_{t-1}(\mathbf{x}_i)} (e^{\alpha} - e^{-\alpha}) \mathbb{I}(f(\mathbf{x}_i) \neq h(\mathbf{x}_i))\end{aligned}$$

做一个简单的符号替换，令 $\mathcal{D}'_t(\mathbf{x}_i) = \mathcal{D}(\mathbf{x}_i) e^{-f(\mathbf{x}_i)H_{t-1}(\mathbf{x}_i)}$ ，并且注意到 $e^{-\alpha}$ 和 $e^{\alpha} - e^{-\alpha}$ 与求和变量 $i$ 无关，可以提取出来，有

$$\ell_{\text{exp}}(H_{t-1} + \alpha h \mid \mathcal{D}) = e^{-\alpha} \sum_{i=1}^{|D|} \mathcal{D}'_t(\mathbf{x}_i) + (e^{\alpha} - e^{-\alpha}) \sum_{i=1}^{|D|} \mathcal{D}'_t(\mathbf{x}_i) \mathbb{I}(f(\mathbf{x}_i) \neq h(\mathbf{x}_i))$$

$$\ell_{\text{exp}}(H_{t-1} + \alpha h \mid \mathcal{D}) = e^{-\alpha} \sum_{i=1}^{|D|} \mathcal{D}'_t(\mathbf{x}_i) + (e^{\alpha} - e^{-\alpha}) \sum_{i=1}^{|D|} \mathcal{D}'_t(\mathbf{x}_i) \mathbb{I}(f(\mathbf{x}_i) \neq h(\mathbf{x}_i))$$

我们的目的是求解 $h_t$ 使得 $\ell_{\text{exp}}$ 最小化，因此可以忽略掉与 $h$ 无关的项，即求解目标是

$$h_t = \arg \min_h (e^{\alpha} - e^{-\alpha}) \sum_{i=1}^{|D|} \mathcal{D}'_t(\mathbf{x}_i) \mathbb{I}(f(\mathbf{x}_i) \neq h(\mathbf{x}_i))$$

更进一步，由于 $\alpha > \frac{1}{2}$ ，易证得 $e^{\alpha} - e^{-\alpha} > 0$ 恒成立，因此求解目标为：

$$h_t = \arg \min_h \sum_{i=1}^{|D|} \mathcal{D}'_t(\mathbf{x}_i) \mathbb{I}(f(\mathbf{x}_i) \neq h(\mathbf{x}_i))$$



$$h_t = \arg \min_h \sum_{i=1}^{|D|} \mathcal{D}'_t(\mathbf{x}_i) \mathbb{I}(f(\mathbf{x}_i) \neq h(\mathbf{x}_i))$$

其中  $\mathcal{D}'_t(\mathbf{x}_i) = \mathcal{D}(\mathbf{x}_i) e^{-f(\mathbf{x}_i)H_{t-1}(\mathbf{x}_i)}$

观察  $\mathcal{D}'_t(\mathbf{x}_i)$  的形式可以发现它仅与  $t - 1$  轮及以前的学习器有关，因此在求解  $h_t$  时，对于每个样本  $i$ ，他其实已经固定了，如果把  $\mathcal{D}'_t(\mathbf{x}_i)$  看做样本  $i$  在  $t$  轮学习时的权重分布，我们要依据这个权重求解学习器  $h_t$  以满足上面的最优化式子。

同时，为了确保  $\mathcal{D}'_t(\mathbf{x}_i)$  是一个分布，通常我们对其进行规范化后作为下一个学习器的输入样本权重，即  $\mathcal{D}_t(\mathbf{x}_i) = \frac{\mathcal{D}'_t(\mathbf{x}_i)}{\sum_{i=1}^{|D|} \mathcal{D}'_t(\mathbf{x}_i)}$ ，其中分母是常数，因此这个变换不会影响上述最小化的求解。

有意思的一点是， $t$ 轮的样本权重可以通过 $t - 1$ 轮样本权重计算，而无需从头算起，以 $t + 1$ 轮为例，根据迭代公式，有：

$$\begin{aligned}\mathcal{D}_{t+1}(\mathbf{x}_i) &= \mathcal{D}(\mathbf{x}_i) e^{-f(\mathbf{x}_i)H_t(\mathbf{x}_i)} \\ &= \mathcal{D}(\mathbf{x}_i) e^{-f(\mathbf{x}_i)(H_{t-1}(\mathbf{x}_i) + \alpha_t h_t(\mathbf{x}_i))} \\ &= \mathcal{D}(\mathbf{x}_i) e^{-f(\mathbf{x}_i)H_{t-1}(\mathbf{x}_i)} e^{-f(\mathbf{x}_i)\alpha_t h_t(\mathbf{x}_i)} \\ &= \mathcal{D}_t(\mathbf{x}_i) e^{-f(\mathbf{x}_i)\alpha_t h_t(\mathbf{x}_i)}\end{aligned}$$

这便是《机器学习》式8.19

## Adaboost算法7

下面求解学习器 $h_t$ 的权重 $\alpha_t$ 。损失函数 $\ell_{\text{exp}}(H_{t-1} + \alpha h \mid \mathcal{D})$ 对 $\alpha$ 求导有：

$$\begin{aligned} \frac{\partial \ell_{\text{exp}}(H_{t-1} + \alpha h_t \mid \mathcal{D})}{\partial \alpha} &= \frac{\partial \left( e^{-\alpha} \sum_{i=1}^{|D|} \mathcal{D}'_t(\mathbf{x}_i) + (e^{\alpha} - e^{-\alpha}) \sum_{i=1}^{|D|} \mathcal{D}'_t(\mathbf{x}_i) \mathbb{I}(f(\mathbf{x}_i) \neq h(\mathbf{x}_i)) \right)}{\partial \alpha} \\ &= -e^{-\alpha} \sum_{i=1}^{|D|} \mathcal{D}'_t(\mathbf{x}_i) + (e^{\alpha} + e^{-\alpha}) \sum_{i=1}^{|D|} \mathcal{D}'_t(\mathbf{x}_i) \mathbb{I}(f(\mathbf{x}_i) \neq h(\mathbf{x}_i)) \end{aligned}$$

令导数等于0，移项可得：

$$\begin{aligned} \frac{e^{-\alpha}}{e^{\alpha} + e^{-\alpha}} &= \frac{\sum_{i=1}^{|D|} \mathcal{D}'_t(\mathbf{x}_i) \mathbb{I}(f(\mathbf{x}_i) \neq h(\mathbf{x}_i))}{\sum_{i=1}^{|D|} \mathcal{D}'_t(\mathbf{x}_i)} = \sum_{i=1}^{|D|} \frac{\mathcal{D}'_t(\mathbf{x}_i)}{Z_t} \mathbb{I}(f(\mathbf{x}_i) \neq h(\mathbf{x}_i)) \\ &= \sum_{i=1}^{|D|} \mathcal{D}_t(\mathbf{x}_i) \mathbb{I}(f(\mathbf{x}_i) \neq h(\mathbf{x}_i)) = \mathbb{E}_{\mathbf{x} \sim \mathcal{D}_t} [\mathbb{I}(f(\mathbf{x}_i) \neq h(\mathbf{x}_i))] = \epsilon_t \end{aligned}$$

$$\begin{aligned}\frac{e^{-\alpha}}{e^{\alpha} + e^{-\alpha}} &= \frac{1}{e^{2\alpha} + 1} \Rightarrow e^{2\alpha} + 1 = \frac{1}{\epsilon_t} \Rightarrow e^{2\alpha} = \frac{1 - \epsilon_t}{\epsilon_t} \Rightarrow 2\alpha = \ln \left( \frac{1 - \epsilon_t}{\epsilon_t} \right) \\ \Rightarrow \alpha_t &= \frac{1}{2} \ln \left( \frac{1 - \epsilon_t}{\epsilon_t} \right)\end{aligned}$$

这便是《机器学习》式8.11

当 $\epsilon > \frac{1}{2}$ 时，上式单调递减，因此误差率越大的学习器分配的权重越少。

输入: 训练集  $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ ;  
基学习算法  $\mathcal{L}$ ;  
训练轮数  $T$ .

过程:

- 1:  $\mathcal{D}_1(x) = 1/m$ .
- 2: **for**  $t = 1, 2, \dots, T$  **do**
- 3:    $h_t = \mathcal{L}(D, \mathcal{D}_t)$ ;
- 4:    $\epsilon_t = P_{\mathbf{x} \sim \mathcal{D}_t}(h_t(\mathbf{x}) \neq f(\mathbf{x}))$ ;
- 5:   **if**  $\epsilon_t > 0.5$  **then break**
- 6:    $\alpha_t = \frac{1}{2} \ln \left( \frac{1 - \epsilon_t}{\epsilon_t} \right)$ ;
- 7:   
$$\mathcal{D}_{t+1}(\mathbf{x}) = \frac{\mathcal{D}_t(\mathbf{x})}{Z_t} \times \begin{cases} \exp(-\alpha_t), & \text{if } h_t(\mathbf{x}) = f(\mathbf{x}) \\ \exp(\alpha_t), & \text{if } h_t(\mathbf{x}) \neq f(\mathbf{x}) \end{cases}$$
$$= \frac{\mathcal{D}_t(\mathbf{x}) \exp(-\alpha_t f(\mathbf{x}) h_t(\mathbf{x}))}{Z_t}$$
- 8: **end for**

输出:  $H(\mathbf{x}) = \text{sign} \left( \sum_{t=1}^T \alpha_t h_t(\mathbf{x}) \right)$

图 8.3 AdaBoost 算法

下一节：Bagging、随机森林、多样性增强

增补知识点：GB(Gradient Boosting)/GBDT/XGBoost

西瓜书对应章节：8.3 8.5

增补知识点参考资料：略

## 结束语

欢迎加入【南瓜书读者交流群】，我们将在群里进行答疑、勘误、本次直播回放、本次直播PPT发放、下次直播通知等最新资源发放和活动通知。

加入步骤：

1. 关注公众号【Datawhale】，发送【南瓜书】三个字获取机器人“小豚”的微信二维码
2. 添加“小豚”为微信好友，然后对“小豚”发送【南瓜书】三个字即可自动邀请进群

