



《机器学习公式详解》 (南瓜书)

第8章 集成学习 (下)

本节主讲：秦州

南瓜书对应章节：8.3、8.4

- 0. 增补知识点：GB(Gradient Boosting)/GBDT/XGBoost
 - 1. Bagging
 - 2. 随机森林 (Random Forest)
 - 3. 多样性增强方法

将AdaBoost问题一般化，即不限定损失函数为指数函数，也不限定局限于二分类问题，那么更一般的Boosting形式为：

$$\begin{aligned}\ell(H_t \mid \mathcal{D}) &= \mathbb{E}_{\mathbf{x} \sim \mathcal{D}} [\text{err}(H_t(\mathbf{x}), f(\mathbf{x}))] \\ &= \mathbb{E}_{\mathbf{x} \sim \mathcal{D}} [\text{err}(H_{t-1}(\mathbf{x}) + \alpha_t h_t(\mathbf{x}), f(\mathbf{x}))]\end{aligned}$$

比如当我们研究是回归问题时， $f(x) \in \mathbb{R}$ 且损失函数为平方损失函数
 $\text{err}(H_t(\mathbf{x}), f(\mathbf{x})) = (H_t(\mathbf{x}) - f(\mathbf{x}))^2$

类似于 AdaBoost, 第 t 轮得到 $\alpha_t, h_t(\mathbf{x})$, 可先对损失函数在 $H_{t-1}(\mathbf{x})$ 处进行泰勒展开:

$$\begin{aligned}\ell(H_t | \mathcal{D}) &\approx \mathbb{E}_{\mathbf{x} \sim \mathcal{D}} \left[\text{err}(H_{t-1}(\mathbf{x}), f(\mathbf{x})) + \frac{\partial \text{err}(H_t(\mathbf{x}), f(\mathbf{x}))}{\partial H_t(\mathbf{x})} \bigg|_{H_t(\mathbf{x})=H_{t-1}(\mathbf{x})} (H_t(\mathbf{x}) - H_{t-1}(\mathbf{x})) \right] \\ &= \mathbb{E}_{\mathbf{x} \sim \mathcal{D}} \left[\text{err}(H_{t-1}(\mathbf{x}), f(\mathbf{x})) + \frac{\partial \text{err}(H_t(\mathbf{x}), f(\mathbf{x}))}{\partial H_t(\mathbf{x})} \bigg|_{H_t(\mathbf{x})=H_{t-1}(\mathbf{x})} \alpha_t h_t(\mathbf{x}) \right] \\ &= \mathbb{E}_{\mathbf{x} \sim \mathcal{D}} [\text{err}(H_{t-1}(\mathbf{x}), f(\mathbf{x}))] + \mathbb{E}_{\mathbf{x} \sim \mathcal{D}} \left[\frac{\partial \text{err}(H_t(\mathbf{x}), f(\mathbf{x}))}{\partial H_t(\mathbf{x})} \bigg|_{H_t(\mathbf{x})=H_{t-1}(\mathbf{x})} \alpha_t h_t(\mathbf{x}) \right]\end{aligned}$$

上式中括号内第1项为常量 $\ell(H_{t-1} \mid \mathcal{D})$ ，因此最小化 $\ell(H_t \mid \mathcal{D})$ 只需要最小化第二项即可。先不考虑 α_t ，求解如下优化问题即可得到 $h_t(\mathbf{x})$ ：

$$h_t(\mathbf{x}) = \arg \min_h \mathbb{E}_{\mathbf{x} \sim \mathcal{D}} \left[\left. \frac{\partial \text{err}(H_t(\mathbf{x}), f(\mathbf{x}))}{\partial H_t(\mathbf{x})} \right|_{H_t(\mathbf{x})=H_{t-1}(\mathbf{x})} h(\mathbf{x}) \right] \quad \text{s.t. constraints for } h(\mathbf{x})$$

解得 $h_t(\mathbf{x})$ 之后，再求解如下优化问题可得权重项 α_t ：

$$\alpha_t = \arg \min_{\alpha} \mathbb{E}_{\mathbf{x} \sim \mathcal{D}} [\text{err}(H_{t-1}(\mathbf{x}) + \alpha h_t(\mathbf{x}), f(\mathbf{x}))]$$

以上就是梯度提升(Gradient Boosting)的理论框架，即每轮通过梯度(Gradient)下降的方式将个体弱学习器提升(Boosting)为强学习器。可以看出 AdaBoost 是其特殊形式。

Adaboost 再推导

$$\begin{aligned}h_t(\boldsymbol{x}) &= \arg \min_h \mathbb{E}_{\boldsymbol{x} \sim \mathcal{D}} \left[\frac{\partial \text{err}(H_t(\boldsymbol{x}), f(\boldsymbol{x}))}{\partial H_t(\boldsymbol{x})} \bigg|_{H_t(\boldsymbol{x})=H_{t-1}(\boldsymbol{x})} h(\boldsymbol{x}) \right] \\&= \arg \min_h \mathbb{E}_{\boldsymbol{x} \sim \mathcal{D}} \left[\frac{\partial e^{-f(\boldsymbol{x})H_t(\boldsymbol{x})}}{\partial H_t(\boldsymbol{x})} \bigg|_{H_t(\boldsymbol{x})=H_{t-1}(\boldsymbol{x})} h(\boldsymbol{x}) \right] \\&= \arg \min_h \mathbb{E}_{\boldsymbol{x} \sim \mathcal{D}} \left[-f(\boldsymbol{x}) e^{-f(\boldsymbol{x})H_{t-1}(\boldsymbol{x})} h(\boldsymbol{x}) \right] = \arg \min_h \mathbb{E}_{\boldsymbol{x} \sim \mathcal{D}} [-f(\boldsymbol{x})h(\boldsymbol{x})]\end{aligned}$$

由 $f(\boldsymbol{x}), h(\boldsymbol{x}) \in \{-1, 1\}$, 有

$$f(\boldsymbol{x})h(\boldsymbol{x}) = 1 - 2\mathbb{I}(f(\boldsymbol{x}) \neq h(\boldsymbol{x}))$$

因此, 得到《机器学习》式8.18

$$h_t(\boldsymbol{x}) = \arg \min_h \mathbb{E}_{\boldsymbol{x} \sim \mathcal{D}_t} [\mathbb{I}(f(\boldsymbol{x}) \neq h(\boldsymbol{x}))]$$

GBDT 以Gradient Boosting为基本框架，并使用CART作为个体学习器。

1. 针对回归问题，GBDT 采用平方损失作为损失函数。 $\text{err}(H_t(\boldsymbol{x}), f(\boldsymbol{x})) = (H_t(\boldsymbol{x}) - f(\boldsymbol{x}))^2$
2. 针对二分类问题，GBDT采用对数似然损失函数 $\text{err}(H_t(\boldsymbol{x}), f(\boldsymbol{x})) = \log(1 + \exp(-H_t(\boldsymbol{x})f(\boldsymbol{x})))$

XGBoost 即eXtreme Gradient Boosting的缩写，XGBoost 与GBDT的关系可以类比为LIBSVM和SVM的关系，即XGBoost是GBDT的一种高效实现和改进。

Bagging

Bagging是并行式集成学习的代表。我们可采样出 T 个含 m 训练样本的采样集，基于每个采样集训练一个基学习器然后将他们结合起来进行预测。

输入: 训练集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$;

基学习算法 \mathcal{L} ;

训练轮数 T .

过程:

1: **for** $t = 1, 2, \dots, T$ **do**

2: $h_t = \mathcal{L}(D, \mathcal{D}_{bs})$

3: **end for**

输出: $H(x) = \arg \max_{y \in \mathcal{Y}} \sum_{t=1}^T \mathbb{I}(h_t(x) = y)$

图 8.5 Bagging 算法

自助采样法 (bootstrap sampling) :

假设从 n 个样本有放回地抽出 n 个样本， n 次抽样后，有的样本会重复被抽到，有的样本没有被抽到，取没有被抽到的样本作为验证集，它们占比约为：

$$\lim_{n \rightarrow \infty} \left(1 - \frac{1}{n}\right)^n = \frac{1}{e} \approx 36.6\%$$

随机森林 (Random Forest) 是Bagging的一个扩展变体，在以决策树为基学习器构建Bagging集成的基础上，进一步在决策树的训练过程中引入了属性的随机选择。

假设样本包含 d 个属性对基决策树的每个节点，先从该节点的属性结合中随机选择包含 k ($k \leq d$) 个属性的子集用来进行最优划分。

随机森林训练效率通常优于Bagging，因为每个节点的划分只需要部分属性参与，而随机森林的泛化误差通常低于bagging，因为属性的扰动为每个基决策树提供了更高的鲁棒性（不易过拟合到训练集上）。

1. 数据样本扰动

- 对输入扰动敏感的基学习器：决策树、神经网络等
- 对输入扰动不敏感的基学习器：线性学习器、支持向量机、朴素贝叶斯、k近邻等

2. 输入属性扰动

- 对包含有大量冗余属性的数据能够大幅加速训练效率

3. 输出属性扰动

- 随机改变一些训练样本的标记
- Dropout

4. 算法参数扰动

- L1、L2正则化等

下一节：聚类、性能和距离度量、原型聚类和密度聚类
西瓜书对应章节：第9章

结束语

欢迎加入【南瓜书读者交流群】，我们将在群里进行答疑、勘误、本次直播回放、本次直播PPT发放、下次直播通知等最新资源发放和活动通知。

加入步骤：

1. 关注公众号【Datawhale】，发送【南瓜书】三个字获取机器人“小豚”的微信二维码
2. 添加“小豚”为微信好友，然后对“小豚”发送【南瓜书】三个字即可自动邀请进群

