



《机器学习公式详解》 (南瓜书)

第12章 计算学习理论 (上)

本节主讲：秦州

南瓜书对应章节：12.1 12.2 12.3

1. 计算学习理论概念
2. PAC学习
3. 有限空间假设

计算学习理论

何为“计算学习”

机器学习 -- 通过“计算”来进行学习的科学

计算学习理论 -- 为机器学习提供理论指导, 分析学习任务的困难度, 指导算法设计

符号:

给定样例集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$, $x_i \in \mathcal{X}$, 假设 \mathcal{X} 中的所有样本都是从一个隐含未知的分布 \mathcal{D} 中独立同分布得采样得到的。

令 h 为从 \mathcal{X} 到 \mathcal{Y} 的一个映射, 其泛化误差为

$$E(h; \mathcal{D}) = P_{x \sim \mathcal{D}}(h(\mathbf{x}) \neq y),$$

h 在 D 上的经验误差为

$$\hat{E}(h; D) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}(h(\mathbf{x}_i) \neq y_i)$$

由于 D 是 \mathcal{D} 的独立同分布采样, 因此 h 的经验误差的期望等于其泛化误差。我们将 $E(h; \mathcal{D})$ 和 $\widehat{E}(h; D)$ 分别简记为 $E(h)$ 和 $\widehat{E}(h)$. 令 ϵ 为 $E(h)$ 的上限, 即 $E(h) \leq \epsilon$; 我们通常用 ϵ 表示预先设定的学得模型所应满足的误差要求, 亦称“误差参数”。

在计算学习理论中, 我们将会研究经验误差与泛化误差之间的逼近程度. 若 h 在数据集 D 上的经验误差为 0, 则称 h 与 D 一致, 否则称其与 D 不一致。对任意两个映射 $h_1, h_2 \in \mathcal{X} \rightarrow \mathcal{Y}$, 可通过其“不合” (disagreement) 来度量它们之间的差别:

$$d(h_1, h_2) = P_{\mathbf{x} \sim \mathcal{D}}(h_1(\mathbf{x}) \neq h_2(\mathbf{x})).$$

PAC (概率近似正确理论) :

“概念” (concept), 记作 c , 表示从样本空间 \mathcal{X} 到标记空间 \mathcal{Y} 的映射。如果 $c(\mathbf{x}) = y$ 成立, 则称 c 为目标概念。

“概念类” (concept class), 记作 \mathcal{C} , 表示所有我们希望学得的目标概念所构成的集合。

“假设” (hypothesis) , 记作 h , 也是从样本空间 \mathcal{X} 到标记空间 \mathcal{Y} 的映射, h 是学习算法学到的。

“假设空间” (hypothesis space), 记作 \mathcal{H} , 表示给定学习算法 \mathcal{L} 所考虑的所有可能假设的集合。

“可分的” (separable), 又称 “一致的” (consistent): 若目标概念 $c \in \mathcal{H}$, 则 \mathcal{H} 中存在假设能将所有示例按与真实标记一致的方式完全分开, 我们称该问题对学习算法 \mathcal{L} 是可分的; 反之是“不可分的”或者叫“不一致的”。

PAC 辨识 (PAC Identify): 对 $0 < \epsilon, \delta < 1$, 所有 $c \in \mathcal{C}$ 和分布 \mathcal{D} , 若存在学习算法 \mathcal{L} , 其输出假设 $h \in \mathcal{H}$ 满足

$$P(E(h) \leq \epsilon) \geq 1 - \delta$$

则称学习算法 \mathcal{L} 能从假设空间 \mathcal{H} 中 PAC 辨识概念类 \mathcal{C} .

通俗来讲, 学习算法 \mathcal{L} 能以较大的概率 (至少 $1 - \delta$) 学得目标概念 c 的近似 (误差最多为 ϵ).

PAC 可学习 (PAC Learnable): 令 m 表示从分布 \mathcal{D} 中独立同分布采样得到的样例数目, $0 < \epsilon, \delta < 1$, 对所有分布 \mathcal{D} , 若存在学习算法 \mathcal{L} 和多项式函数 $\text{poly}(\cdot, \cdot, \cdot, \cdot)$, 使得对于任何 $m \geq \text{poly}(1/\epsilon, 1/\delta, \text{size}(\mathbf{x}), \text{size}(c))$, \mathcal{L} 能从假设空间 \mathcal{H} 中 PAC 辨识概念类 \mathcal{C} , 则称概念类 \mathcal{C} 对假设空间 \mathcal{H} 而言是 PAC 可学习的, 有时也简称概念类 \mathcal{C} 是 PAC 可学习的。其中 \mathcal{L} 称为**PAC学习算法**, 最小的 m 称为**样本复杂度**。

PAC学习的意义：给出了一个抽象地刻画机器学习能力的框架：比如至少需要多少样本才能训练得到较好的模型。

可分情形意味着目标概念 c 属于假设空间 \mathcal{H} , 即 $c \in \mathcal{H}$. 给定包含 m 个样例的训练集 D , 如何找出满足误差参数的假设呢?

一种简单的学习策略: 既然 D 中样例标记都是由目标概念 c 赋予的, 并且 c 存在于假设空间 \mathcal{H} 中, 那么, 任何在训练集 D 上出现标记错误的假设肯定不是目标概念 c . 于是, 我们只需保留与 D 一致的假设, 剔除与 D 不一致的假设即可。【问题, 可能产生很多等效假设】

到底需多少样例才能学得目标概念 c 的有效近似呢? 对 PAC 学习来说, 只要训练集 D 的规模能使学习算法 \mathcal{L} 以概率 $1 - \delta$ 找到目标假设的 ϵ 近似即可。

我们先估计泛化误差大于 ϵ 但在训练集上仍表现完美的假设出现的概率. 假定 h 的泛化误差大于 ϵ , 对分布 \mathcal{D} 上随机采样而得的任何样例 (\mathbf{x}, y) , 有

$$\begin{aligned} P(h(\mathbf{x}) = y) &= 1 - P(h(\mathbf{x}) \neq y) \\ &= 1 - E(h) \\ &< 1 - \epsilon. \end{aligned}$$

由于 D 包含 m 个从 \mathcal{D} 独立同分布采样而得的样例, 因此, h 与 D 表现一致的概率为

$$\begin{aligned} P((h(\mathbf{x}_1) = y_1) \wedge \dots \wedge (h(\mathbf{x}_m) = y_m)) &= (1 - P(h(\mathbf{x}) \neq y))^m \\ &< (1 - \epsilon)^m. \end{aligned}$$

有限假设空间--可分情形3

我们事先并不知道学习算法 \mathcal{L} 会输出 \mathcal{H} 中的哪个假设, 但仅需保证泛化误差大于 ϵ , 且在训练集上表现完美的所有假设出现概率之和不大于 δ 即可:

$$P(h \in \mathcal{H} : E(h) > \epsilon \wedge \widehat{E}(h) = 0) < |\mathcal{H}|(1 - \epsilon)^m < |\mathcal{H}|e^{-m\epsilon}$$

令上式不大于 δ , 即

$$|\mathcal{H}|e^{-m\epsilon} \leq \delta$$

可得

$$m \geq \frac{1}{\epsilon} \left(\ln |\mathcal{H}| + \ln \frac{1}{\delta} \right)$$

由此可知, 有限假设空间 \mathcal{H} 都是 PAC 可学习的。

有限假设空间--不可分情形

显然, 当 $c \notin \mathcal{H}$ 时, 学习算法 \mathcal{L} 无法学得目标概念 c 的 ϵ 近似. 但是, 当假设空间 \mathcal{H} 给定时, 其中必存在一个泛化误差最小的假设, 找出此假设的 ϵ 近似也不失为一个较好的目标. \mathcal{H} 中泛化误差最小的假设是 $\arg \min_{h \in \mathcal{H}} E(h)$, 于是, 以此为目标可将 PAC 学习推广到 $c \notin \mathcal{H}$ 的情况, 这称为“不可知学习” (agnostic learning). 相应的, 我们有

定义 12.5 不可知 PAC 可学习 (agnostic PAC learnable): 令 m 表示从分布 \mathcal{D} 中独立同分布采样得到的样例数目, $0 < \epsilon, \delta < 1$, 对所有分布 \mathcal{D} , 若存在学习算法 \mathcal{L} 和多项式函数 $\text{poly}(\cdot, \cdot, \cdot, \cdot)$, 使得对于任何 $m \geq \text{poly}(1/\epsilon, 1/\delta, \text{size}(\mathbf{x}), \text{size}(c))$, \mathcal{L} 能从假设空间 \mathcal{H} 中输出满足式 (12.20) 的假设 h :

$$P \left(E(h) - \min_{h' \in \mathcal{H}} E(h') \leq \epsilon \right) \geq 1 - \delta,$$

则称假设空间 \mathcal{H} 是不可知 PAC 可学习的.

下一节：计算学习理论（下）

西瓜书对应章节：12.4 12.5 12.6

欢迎加入【南瓜书读者交流群】，我们将在群里进行答疑、勘误、本次直播回放、本次直播PPT发放、下次直播通知等最新资源发放和活动通知。

加入步骤：

1. 关注公众号【Datawhale】，发送【南瓜书】三个字获取机器人“小豚”的微信二维码
2. 添加“小豚”为微信好友，然后对“小豚”发送【南瓜书】三个字即可自动邀请进群

